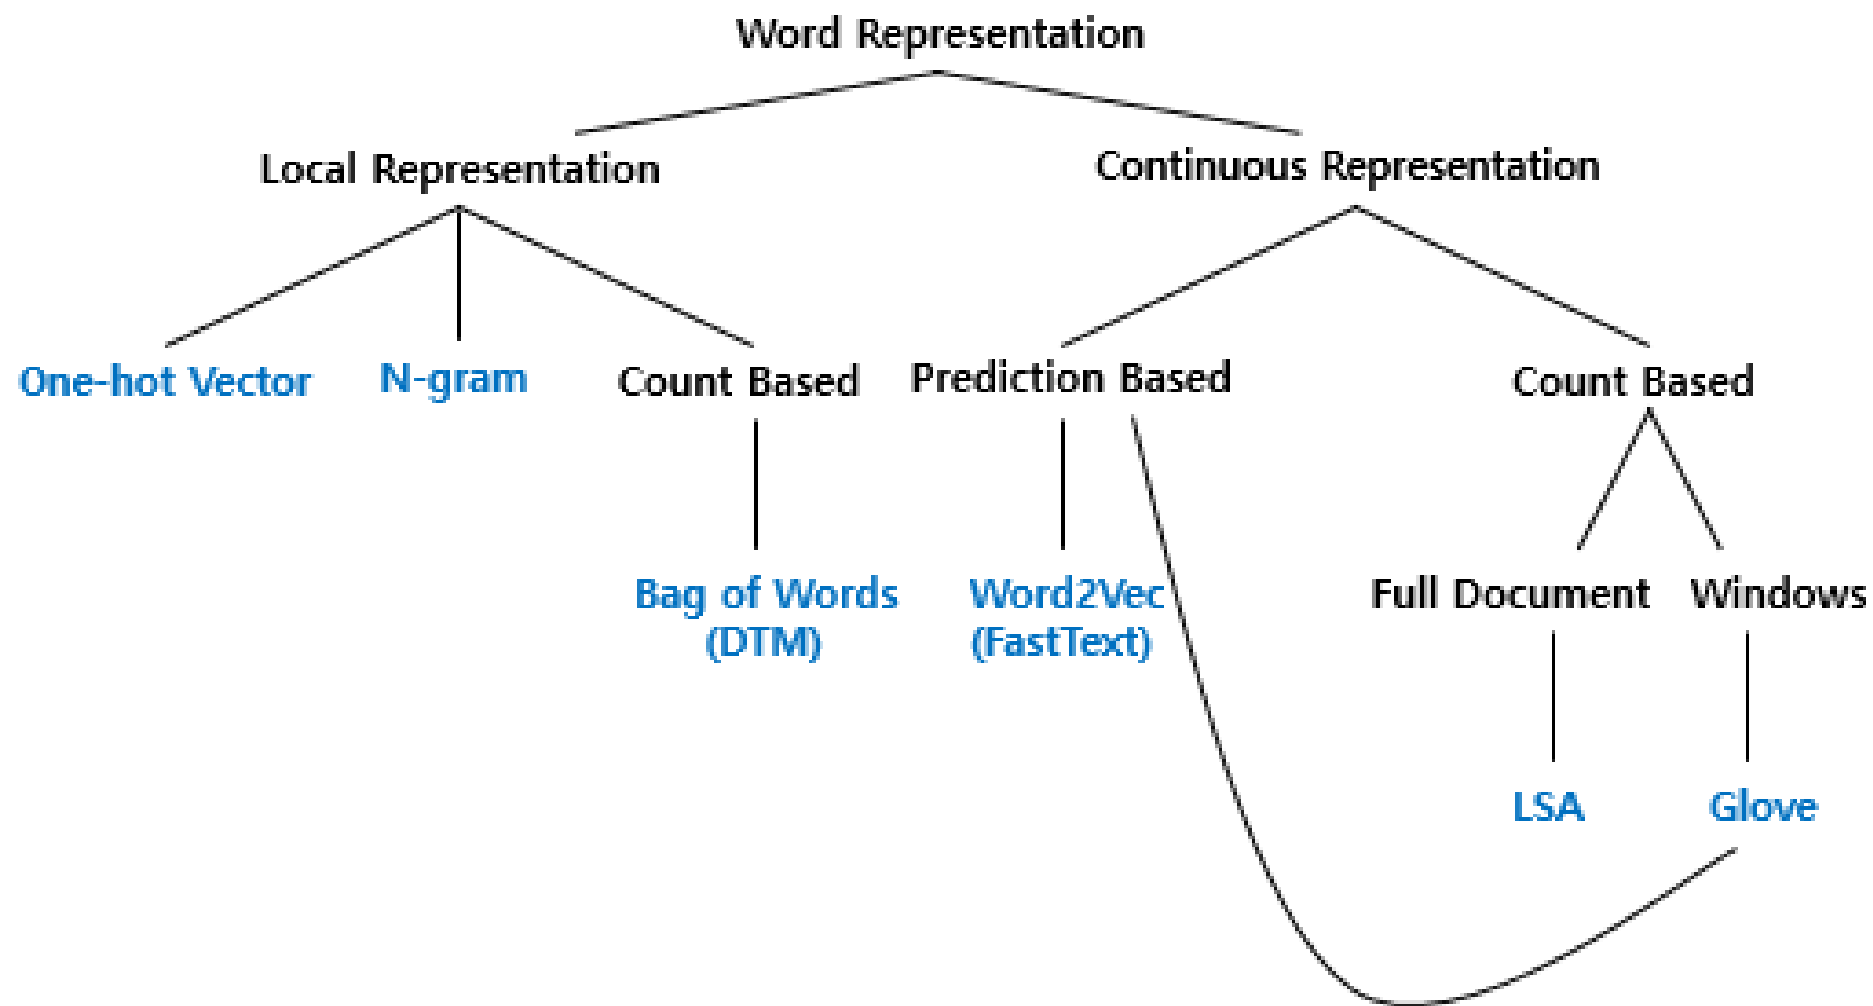


Lecture 6: 문서 표현과 확률적 언어 모형 (Probabilistic Language Model)

Word Representation



카운트 기반의 문서 표현 및 활용

카운트 기반의 문서 표현

-
- 문서를 단어의 나열로 보는 것이 아니라 단어의 통계로 보려는 시각
- “어떤 단어가 몇 번 쓰였는가?” 이것 만으로도 문서에 대한 짐작이 가능

BOW

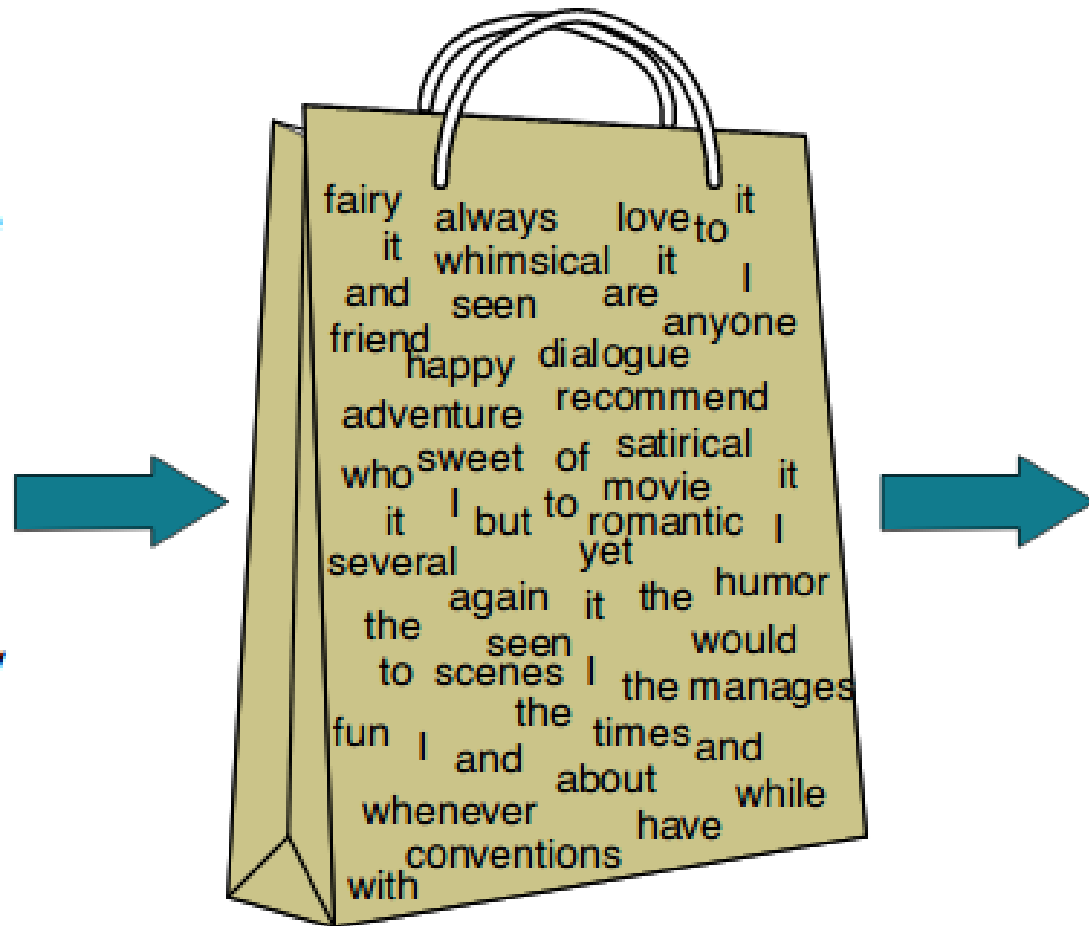
- 문서를 단어들의 sequence가 아닌 bag으로 표현
- tokenize된 결과를 이용하여 문서를 각 단어의 유무 혹은 개수로 이루어진 vector로 변환

텍스트와 특성 (feature)

- 텍스트 마이닝을 위해서는 대상이 되는 텍스트를 우리가 다룰 수 있는 수치 형태로 변환
- 특성(feature)
 - 대상이 갖고 있는 정보 중 우리가 관심이 있는 것을 표현
 - ex) 사람의 특성: 이름, 나이, 키, 몸무게 등
- 텍스트의 특성
 - 텍스트를 이해할 수 있는 특성은 무엇인가?
- 카운트 기반의 문서표현
 - 텍스트의 특성을 단어(토큰)로 표현
 - 텍스트에서 '쓰였다'/'안쓰였다'로 구분하기 위해 True/False로 표현
 - 혹은 그 단어가 텍스트에서 사용된 횟수를 특성 값으로 사용

Bag of Words (BoW)

I love this movie! It's sweet, but with satirical humor. The dialogue is great and the adventure scenes are fun... It manages to be whimsical and romantic while laughing at the conventions of the fairy tale genre. I would recommend it to just about anyone. I've seen it several times, and I'm always happy to see it again whenever I have a friend who hasn't seen it yet!



it	6
I	5
the	4
to	3
and	3
seen	2
yet	1
would	1
whimsical	1
times	1
sweet	1
satirical	1
adventure	1
genre	1
fairy	1
humor	1
have	1
great	1
...	...

Bag of Words (BoW)

- Vector Space Model (one-hot vector)
 - 문서를 bag of words 로 표현
 - 단어가 쓰여진 순서는 무시
 - 모든 문서에 한번 이상 나타난 단어들에 대해 유(1)/무(0) 로 문서를 표현
- Count Vector
 - 단어의 유/무 대신 단어가 문서에 나타난 횟수로 표현
 - count가 weight로 작용

문서 단어 행렬 (DTM)

- 문서 단어 행렬(Document-Term Maxtrix, DTM)은 다수의 문서 데이터(=Corpus)에서 등장한 모든 단어의 출현 빈도수(frequency)를 행렬로 표현한 것
- DTM은 다수의 문서 데이터에 대한 Bag of Words(BoW)를 행렬로 표현한 것
- DTM은 국소 표현(Local Representation) 또는 이산 표현(Discrete Representation)의 일종으로 카운트 기반의 단어 표현방법

DTM 한계점

희소 행렬 표현(Sparse Matrix Representation)

- DTM은 문서 개수와 문서 내 모든 단어 집합의 크기만큼의 차원을 갖는다
- 문서 데이터가(=row 개수) 방대해질수록 단어 집합의 크기(=column 개수)는 기하급수적으로 증가하기 때문에, DTM은 수만, 수십만 이상의 차원을 가질 수 있다.
- 차원의 개수가 커진 만큼 계산의 복잡도는 증가하기 때문에 리소스 낭비를 유발
- DTM은 대부분의 column이 0인 행렬 표현방식임에도 불구하고, 단어 집합의 크기만큼 차원을 갖기 때문에 저장공간의 낭비를 유발

단순 빈도수 기반 단어 표현

- DTM은 문서 데이터에서 단어의 빈도수만 고려하기 때문에 중요 단어와 불필요한 단어를 구분하기 어렵다는 한계 존재


TF-IDF (Term Frequency - Inverse Document Frequency)

TF



Frequency of a word
within the document

IDF



Frequency of a word
across the documents

TF-IDF (Term Frequency - Inverse Document Frequency)

- 단어의 count를 단어가 나타난 문서의 수로 나눠서 자주 등장하지 않는 단어의 weight를 올림
- $tf(d, t)$: 문서 d 에 단어 t 가 나타난 횟수, count vector와 동일, 로그스케일 등 다양한 변형이 있음
- $df(t)$: 전체 문서 중에서 단어 t 를 포함하는 문서의 수
- $idf(t)$: $df(t)$ 의 역수를 바로 쓸 수도 있으나, 여러가지 이유로 로그스케일과 스무딩을 적용한 공식을 사용, $\log(n/(1 + df(t)))$, n 은 전체 문서 수

TF-IDF (Term Frequency - Inverse Document Frequency)

- tokenize 결과 예제
 - $d1$: fast, furious, shoot, shoot
 - $d2$: fast, fast, fly, furious
- count vector: $tf(d, t)$

word	fast	fly	furious	shoot
$d1$	1	0	1	2
$d2$	2	1	1	0

- $idf: \log(n / (1 + df(t)))$
 - fast, furious는 두 개의 문서에, fly, shoot는 하나의 문서에 출현
 - 따라서 fast, furious는 중요도가 fly, shoot보다 떨어져야 함
 - n (전체문서수)= 10으로 가정하면, fast의 idf 는 $\log(10 / (1 + 2)) = 0.52$
 - fly의 idf 는 $\log(10 / (1 + 1)) = 0.70$
- TF-IDF: $tf(d, t) * idf(t)$

word	fast	fly	furious	shoot
$d1$	$1 * 0.52$	$1 * 0.70$	$0 * 0.52$	$0 * 0.70$
$d2$	$2 * 0.52$	$0 * 0.70$	$1 * 0.52$	$1 * 0.70$

TF-IDF의 변형

Variants of term frequency (tf) weight

weighting scheme	tf weight
binary	0, 1
raw count	$f_{t,d}$
term frequency	$f_{t,d} / \sum_{t' \in d} f_{t',d}$
log normalization	$\log(1 + f_{t,d})$
double normalization 0.5	$0.5 + 0.5 \cdot \frac{f_{t,d}}{\max_{\{t' \in d\}} f_{t',d}}$
double normalization K	$K + (1 - K) \frac{f_{t,d}}{\max_{\{t' \in d\}} f_{t',d}}$

TF-IDF의 변형

Variants of inverse document frequency (idf) weight

weighting scheme	idf weight ($n_t = \{d \in D : t \in d\} $)
unary	1
inverse document frequency	$\log \frac{N}{n_t} = -\log \frac{n_t}{N}$
inverse document frequency smooth	$\log \left(\frac{N}{1 + n_t} \right) + 1$
inverse document frequency max	$\log \left(\frac{\max_{t' \in d} n_{t'}}{1 + n_t} \right)$
probabilistic inverse document frequency	$\log \frac{N - n_t}{n_t}$

언어 모델의 개념

- 언어 모델(Language Model)은 문장이 얼마나 자연스러운지 확률적으로 계산함으로써 문장 내 특정 위치에 출현하기 적합한 단어를 확률적으로 예측하는 모델
- 언어 모델은 문장 내 앞서 등장한 단어를 기반으로 뒤에 어떤 단어가 등장해야 문장이 자연스러운지 판단하는 도구

언어 모델의 종류

- 통계학적 언어 모델
- 인공지능망 기반의 언어 모델

최근에는 BERT, GPT-3와 같은 인공지능망 기반의 언어 모델의 성능이 뛰어나 대부분의 자연어처리 문제에서는 인공지능망 기반의 언어 모델을 사용

"비행기를 타기 위해 공항을 가는데 차가 너무 막혀서 결국 비행기를 [???"

- 사람은 이 문장에서 '비행기를' 단어 뒤에 이어질 물음표(???)에 들어갈 단어로 '놓쳤다'를 쉽게 예측
- 수많은 단어와 문장을 듣고 쓰고 말하며 언어능력을 학습해왔기 때문에, 확률적으로 '놓쳤다'라는 단어가 가장 적합하다고 판단 가능
- 해당 문장을 기계(=언어 모델)에게 보여주고 물음표에 올 적합한 단어를 예측하라고 하면?
- 기계 역시 사람과 같은 프로세스로 동작
 - 먼저, 언어 모델은 텍스트 기반의 수많은 문장을 통해 어떤 단어가 어떤 어순으로 쓰인 것이 가장 자연스러운 문장인지 학습
 - 이를 통해 언어 모델은 문장이 주어졌을 때 앞뒤에 주어진(=어순) 단어 조합을 기반으로 가장 높은 확률로 등장할 만한 단어를 출력

확률적 언어 모형(Probabilistic Language Model)

수학에서 **시퀀스(Sequence)**는 순서를 고려하여 나열된 여러 객체들의 묶음을 의미한다는 점에서, 문장은 어순을 고려하여 여러 단어로 이루어진 단어 시퀀스(Word Sequence)라고도 함

m 개의 단어로 구성된 단어 시퀀스 W 를 확률적으로 표현하면

$$P(W) = P(w_1, w_2, \dots, w_m)$$

단어 시퀀스 자체의 확률은 모든 단어 (w_1, w_2, \dots, w_m) 예측이 완료되었을 때, 즉 문장이 완성되었을 때 알 수 있다.

단어 시퀀스의 확률은 각 단어의 확률과 단어들의 조건부 확률을 이용하여 다음과 같이 계산

$$\begin{aligned} P(w_1, w_2, \dots, w_m) &= P(w_1, w_2, \dots, w_{m-1}) \cdot P(w_m | w_1, w_2, \dots, w_{m-1}) \\ &= P(w_1, w_2, \dots, w_{m-2}) \cdot P(w_{m-1} | w_1, w_2, \dots, w_{m-2}) \cdot P(w_m | w_1, w_2, \dots, w_{m-1}) \\ &= P(w_1) \cdot P(w_2 | w_1) \cdot P(w_3 | w_1, w_2) P(w_4 | w_1, w_2, w_3) \cdots P(w_m | w_1, w_2, \dots, w_{m-1}) \end{aligned}$$

위 식을 곱연산(product operator)을 활용해 표현하면

$$P(w_1, w_2, \dots, w_m) = P(w_1) \prod_{i=2}^m P(w_i | w_{i-1}, \dots, w_{i-n})$$

여기에서 $P(w_m | w_1, w_2, \dots, w_{m-1})$ 은 지금까지 w_1, w_2, \dots, w_{m-1} 라는 단어 열이 나왔을 때, 그 다음 단어로 w_m 이 나올 조건부 확률을 말한다. 여기에서 지금까지 나온 단어를 **문맥(context)** 정보라고 한다.

언어 모델 활용 예시

기계 번역(Machine Translation)

- 아래와 같이 번역기를 돌린 2가지 문장이 있다고 가정했을 때, 좌측 문장이 우측 문장보다는 자연스러운 문장
- 언어 모델은 좌측 문장이 우측 문장보다 높은 확률을 갖는다고 판단

("나는 지하철을 탔다") > ("나는 지하철을 태웠다")

오타 교정(Spell Correction)

- 키보드 자판의 위치로 인해 아래와 같이 '알아갔다'를 '랄아갔다'로 오타가 발생
- 오타가 발생한 우측 문장보다는 좌측 문장이 자연스러운 문장
- 언어 모델은 좌측 문장의 확률이 우측 문장보다 높다고 판단

("자연어처리 방법론을 알아갔다") > ("자연어처리 방법론을 랄아갔다")

언어 모델 활용 예시

음성 인식(Speech Recognition)

- "신라"는 소리 내어 발음하면 [실라]
- 언어 모델은 이처럼 실제 텍스트와 발음 간의 차이를 교정해 주는 데 활용 가능

("신라의 달밤") > ("실라의 달밤")

검색어 추천(Keyword Search Recommendation)

- 네이버나 구글 검색 시자동완성 기능
- 언어 모델을 통해 사용자가 입력한 단어를 기반으로 뒤이어 입력할 만한 단어를 추천

모형의 종류

이 때 조건부 확률을 어떻게 모형화하는냐에 따라

- 유니그램 모형(Unigram Model)
- 바이그램 모형(Bigram Model)
- N그램 모형(N-gram Model)

유니그램 모형

만약 모든 단어의 활용이 완전히 서로 독립이라면 단어 열의 확률은 다음과 같이 각 단어의 확률의 곱이 된다. 이러한 모형을 유니그램 모형이라고 한다.

$$P(w_1, w_2, \dots, w_m) = \prod_{i=1}^m P(w_i)$$

바이그램 모형

만약 단어의 활용이 바로 전 단어에만 의존한다면 단어 열의 확률은 다음과 같다. 이러한 모형을 바이그램 모형 또는 마코프 모형(Markov Model)이라고 한다.

$$P(w_1, w_2, \dots, w_m) = P(w_1) \prod_{i=2}^m P(w_i | w_{i-1})$$

N그램 모형

만약 단어의 활용이 바로 전 $n - 1$ 개의 단어에만 의존한다면 단어 열의 확률은 다음과 같다. 이러한 모형을 N그램 모형이라고 한다.

$$P(w_1, w_2, \dots, w_m) = P(w_1) \prod_{i=2}^m P(w_i | w_{i-1}, \dots, w_{i-n})$$

조건부 확률의 추정

빈도를 사용한 각각의 조건부 확률 추정

$$P(w|w_c) = \frac{C((w_c, w))}{C((w_c))}$$

위 식에서 $C(w_c, w)$ 은 전체 말뭉치에서 (w_c, w) 라는 바이그램이 나타나는 횟수이고 $C(w_c)$ 은 전체 말뭉치에서 (w_c) 라는 유니그램(단어)이 나타나는 횟수

바이그램 언어 모형

조건부 확률을 알게 되면 각 문장의 확률을 구할 수 있다.

다음으로 이 토큰열을 N-그램형태로 분해한다.

바이그램 모형에서는 전체 문장의 확률은 다음과 같이 조건부 확률의 곱으로 나타난다.

$$P(\text{SS I am a boy SE}) = P(\text{I}|\text{SS}) \cdot P(\text{am}|\text{I}) \cdot P(\text{a}|\text{am}) \cdot P(\text{boy}|\text{a}) \cdot P(\text{.}|\text{boy}) \cdot P(\text{SE}|.)$$

N-gram 기반 단어 예측

N-gram 언어 모델은 이전 $(n - 1)$ 개의 단어를 바탕으로 n 번째 올 단어를 예측

- '오늘 점심 추천 메뉴'에 뒤이어 나올 단어 w 를 예측할 때, n 이 4인 4-gram을 활용한다고 가정
- 4-gram은 3개의 단어만 고려
- '오늘 점심 추천 메뉴'에서 '오늘'이라는 단어는 고려하지 않고 '점심 추천 메뉴'만 고려
- '오늘 점심 추천 메뉴'에서 뒤이어 나올 단어 가 등장할 확률을 수학적으로 표현하면

$$P(w|\text{점심 추천 메뉴}) = \frac{\text{count}(\text{점심 추천 메뉴 } w)}{\text{count}(\text{점심 추천 메뉴})}$$

전체 문서 데이터에서 '점심 추천 메뉴'이라는 문장이 1,000번, '점심 추천 메뉴' 문장 뒤에 '파스타' 단어가 500번 등장하고, '갈비탕'이 300번 등장했다고 가정

$$P(\text{파스타}|\text{점심 추천 메뉴}) = \frac{\text{count}(\text{점심 추천 메뉴 파스타})}{\text{count}(\text{점심 추천 메뉴})} = 0.5$$

$$P(\text{갈비탕}|\text{점심 추천 메뉴}) = \frac{\text{count}(\text{점심 추천 메뉴 갈비탕})}{\text{count}(\text{점심 추천 메뉴})} = 0.3$$

N-gram의 한계점

정확도 문제

- N-gram 언어 모델은 문장 내 전체 단어를 고려하는 언어 모델과 비교했을 때 정확도가 낮음
- N-gram 언어 모델은 이전에 N개의 단어만 고려하기 때문에, 앞 문장의 맥락을 놓치는 경우 발생
- 이는 문장의 앞부분과 뒷부분의 문맥이 매끄럽지 못하게 만들 수 있음
- 예를 들어, N-gram 기반 챗봇을 만들었다고 가정
 - '오늘 점심 메뉴 추천' 다음 이어질 단어를 예측할 때 trigram을 사용하면 '오늘'이라는 단어는 고려하지 않습니다.
 - 만약, 사용자가 '오늘'이 아닌 '내일'의 점심 메뉴를 물어봐도 챗봇은 '오늘' 점심 추천 메뉴와 같은 결과만 출력
- N-gram은 문장 앞부분의 중요한 키워드나 맥락을 놓치는 경우 발생

희소(Sparsity) 문제

- 전체 문서(=Corpus)에서 문장 내 전체 단어를 고려하는 언어 모델과 비교했을 때, N-gram 언어 모델은 일부 단어만 고려하기 때문에 전체 문서에서 특정 단어의 출현 확률을 높일 수 있다는 장점 존재
- 그럼에도 불구하고, 전체 문서에서 N개의 단어를 연속적으로 갖는 문장 자체 개수가 드물다는 희소 문제 존재

상충(Trade-off) 문제

- N-gram 언어 모델은 N값 설정 시 상충(Trade-off) 문제가 존재
- N의 값이 커도 문제이고, 작아도 문제
- N은 최대 5를 넘지 않는 선에서 활용하는 것을 권장
- N을 무작정 크게 설정하면 전체 문서에서 해당 N-gram 문장을 카운팅 할 확률이 낮아지므로 희소 문제 심각
- N이 클수록 언어 모델의 사이즈 증가로 연산 비용도 증가
- N의 값이 너무 작으면 전체 데이터에서 문장 카운팅은 잘 될 수는 있어도, 실질적으로 매끄러운 문장이 만들어지긴 어려움

N의 값에 따른 성능 비교 연구

해당 연구는 월스트리트 저널(Wall Street Journal)에서 3,800만 개의 단어를 기반으로 언어 모델을 학습하고, 1,800만 개의 테스트 데이터를 활용한 테스트를 통해 Perplexity(PPL) 값을 비교

	Unigram	Bigram	Trigram
Perplexity	962	170	109